Hermes：基于 eBPF 的内核连接分发调度优化

阿里云 ALB 团队 左岳尚

陕西 · 西安 2026年4月18日

1. C10K 问题推动了I/O 事件通知机制的发展

经典的 C10K问题: 单服务器如何处理 10K 个并发连接

从 C10K到 C1000K，现代 I/O 事件通知机制不断演进

NGINX envoy HAPROXY COMMUNITY EDITION

The C10K Problem: https://www.kegel.com/c10k.html

2.1 现有机制的问题：Epoll exclusive的连接堆积问题

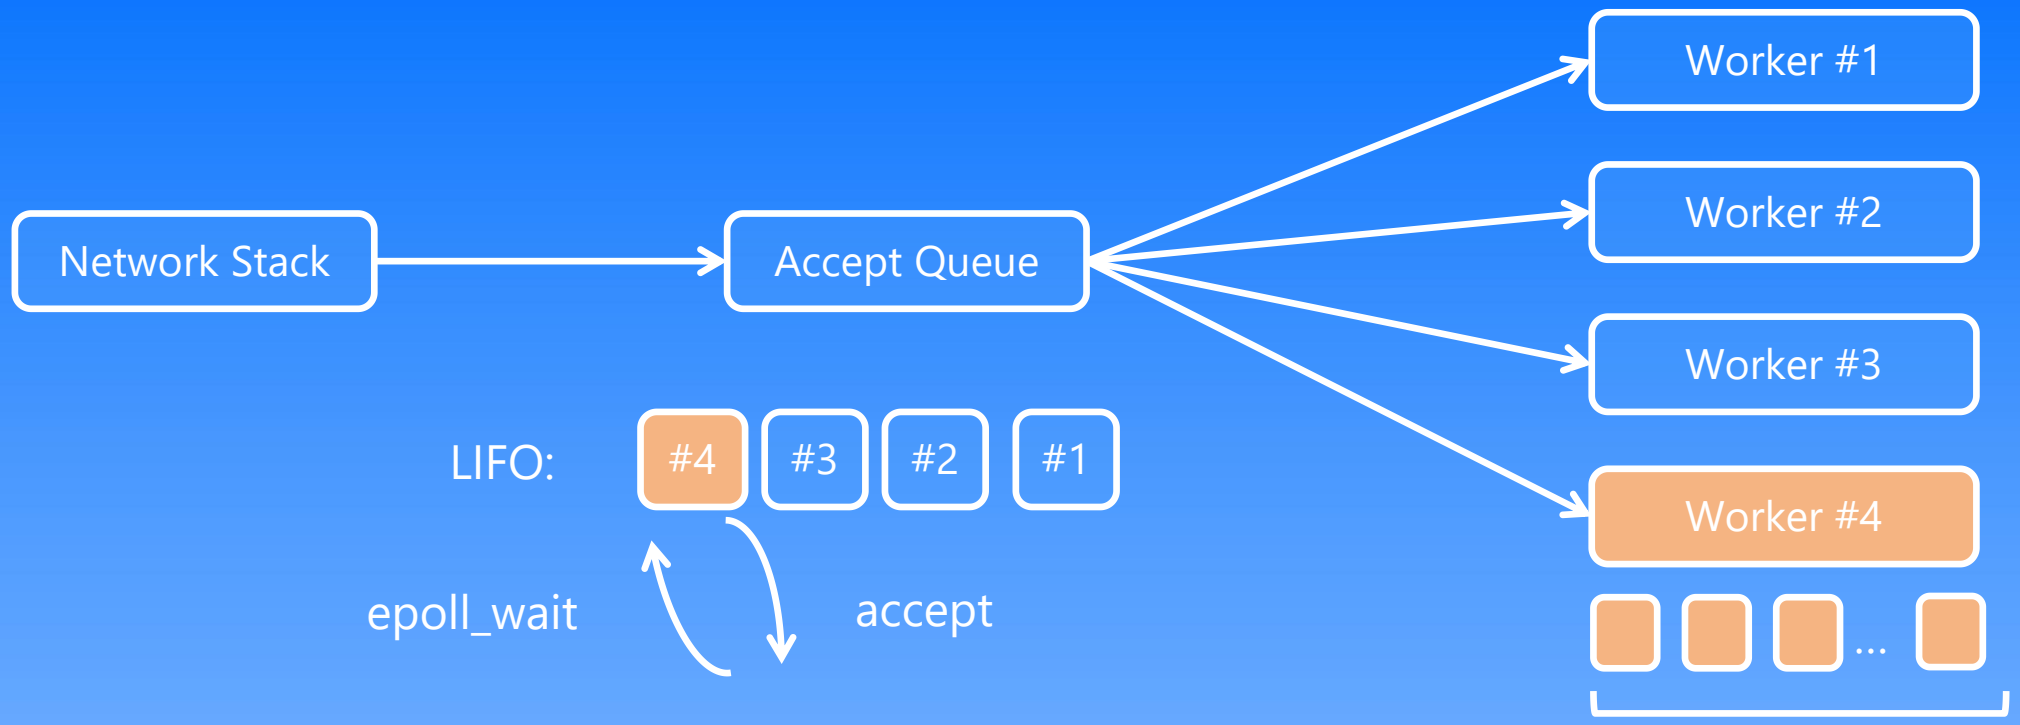

LIFO 的分发顺序导致最近唤醒的 worker 累积最多的连接

Cloudflare 类似的发现: https://blog-cloudflare-com.webpkgcache.com/doc/-/s/blog.cloudflare.com/the-sad-state-of-linux-socket-balancing/

2.2 现有机制的问题：Reuseport 的无状态 hash

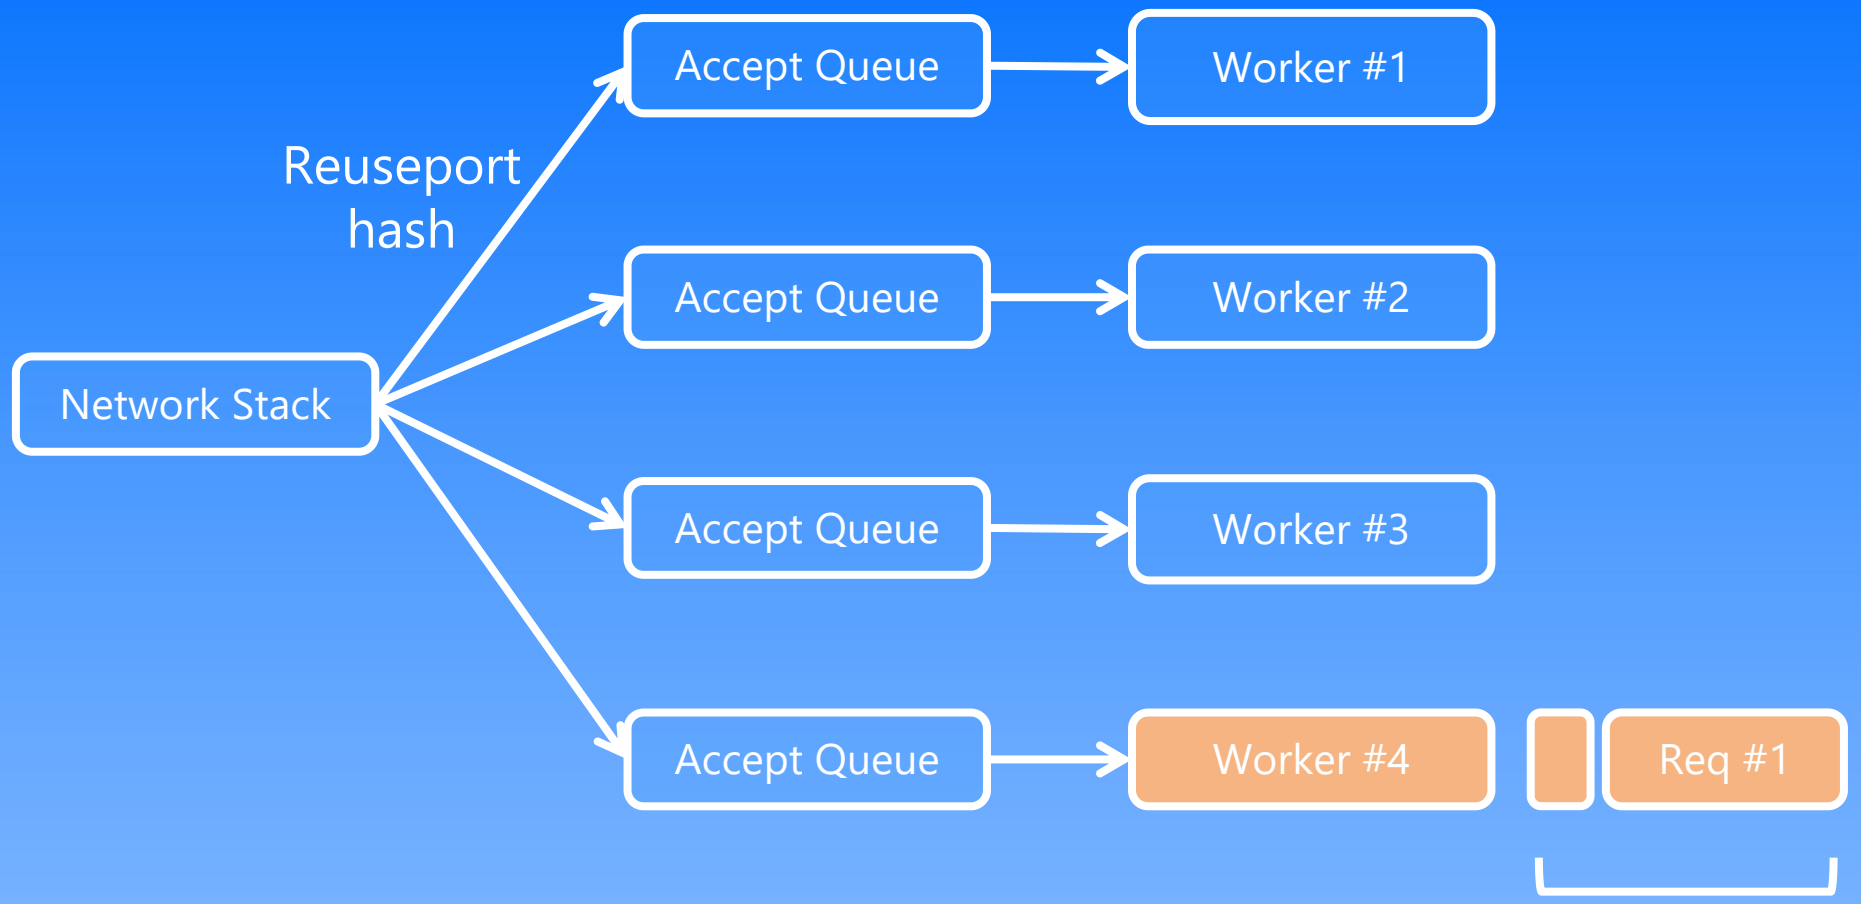

请求仍可能被分发到过载的 worker

3.1 云上多租的天然异构流量模型

Region	请求大小（bytes）			请求处理时间（ms）		
	P50	P90	P99	P50	P90	P99
Region 1	243	312	2491	2	9	42
Region 2	831	3730	10132	10	77	8190
Region 3	566	1951	50879	3	278	49005
Region 4	721	1140	4638	4	14	239

不同 Region 不同租户的流量模型特征差异迥异:

- 请求大小和处理时间因租户/业务不同而差异较大
- 无法找到特定的调度策略来满足所有的流量模型

3.2 现有方法无法满足实际生产环境需要

特定调度方法导致多个 worker 间负载严重不均（某地域 363 台设备）：

- 部分 worker CPU 利用率过高导致延迟抖动
- 木桶效应导致整体的资源利用率不高

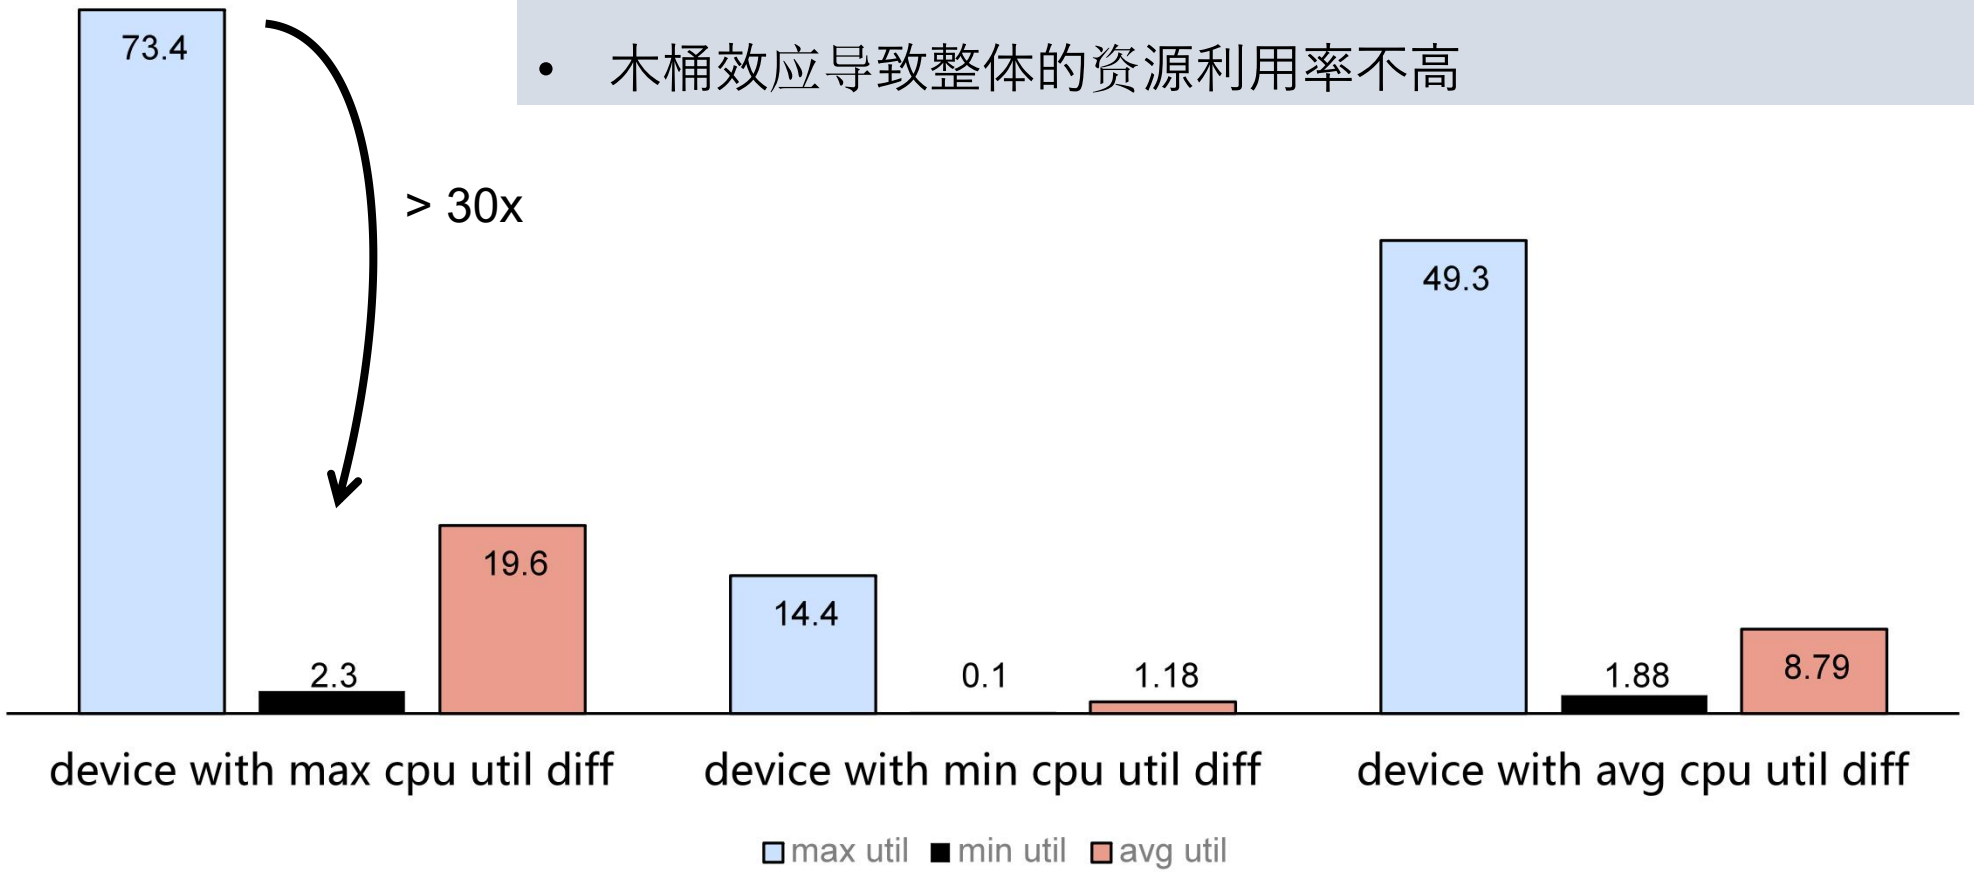

4. 现有方法的核心问题

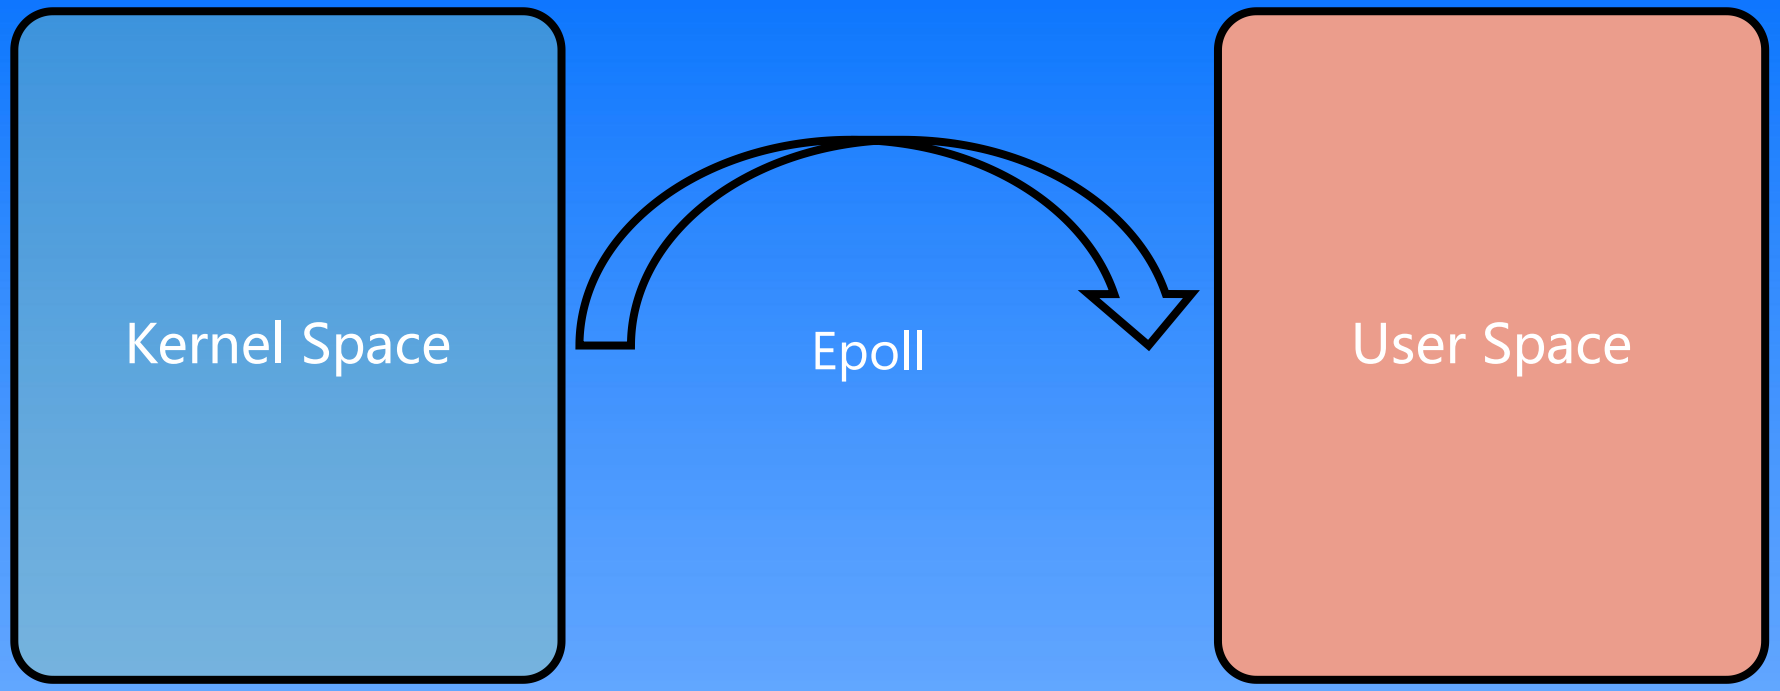

单向的 I/O 事件通知机制没有考虑用户态进程的详细状态，连接可能被分发到过载或者异常的进程

5. Hermes：用户态引导的 I/O 事件通知框架

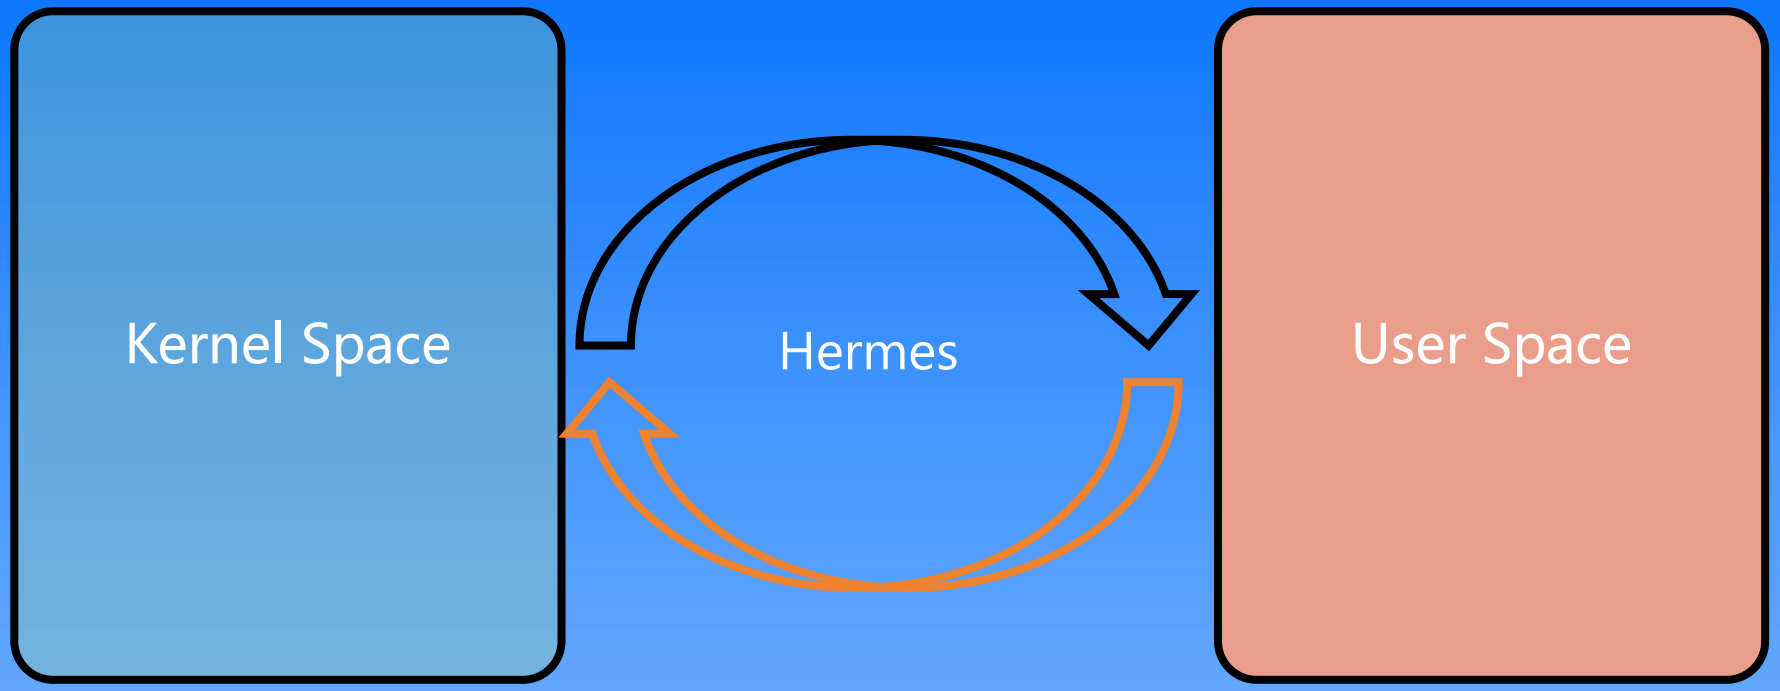

5. Hermes：用户态引导的 I/O 事件通知框架

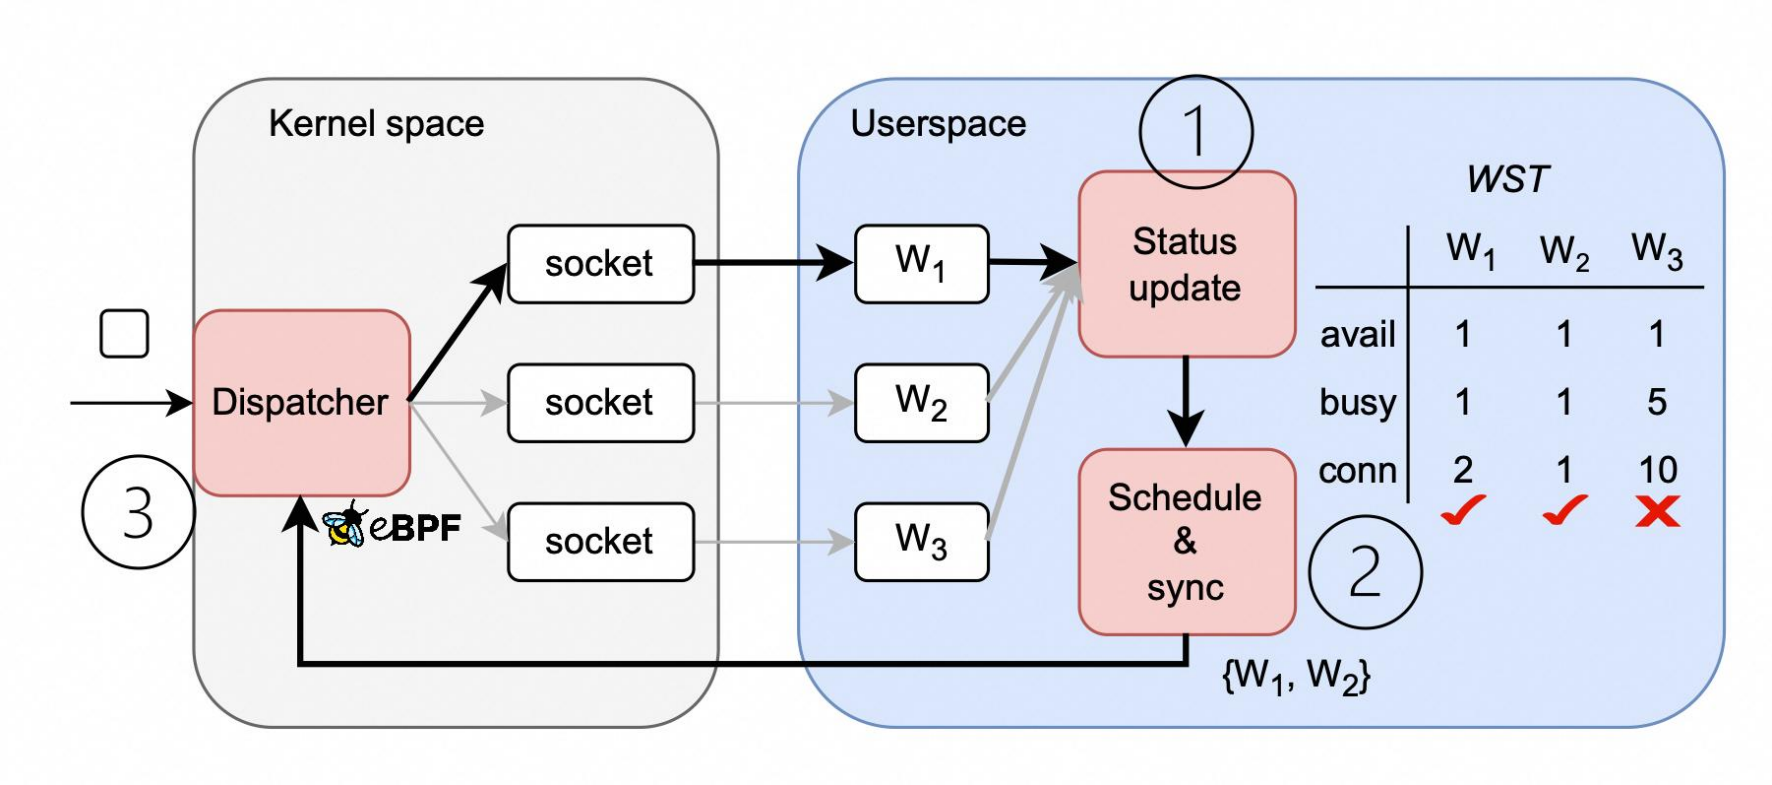

Hermes的闭环控制事件通知框架

1) Status update：

每个worker将自己的runtime状态更新到全局变量WST

2) Schedule & sync：

每个worker通过WST获取其他所有worker的状态，从而在用户态计算出多个合适的worker，并将计算结果同步给内核

3) Dispatcher：

内核在多个合适的worker中选择进行连接分发

5.1 Hermes实现：指标的选取与用户态筛选

选取三个有效指标：进入event loop的时间，worker累积连接数量，worker待处理事件数量

Algorithm 1: Scheduler

```
Function schedule_and_sync():
    W ← {w_1, ···, w_n}
    time, event, conn ← Read_SHM()
    W ← FilterTime(time, W)
    W ← FilterCount(conn, W)
    W ← FilterCount(event, W)
    SelWorker ← Array2INT(W)
    BPF_MAP_UPDATE(SelWorker, M_Sel)
Function FilterTime(R, W):
    return {w_i | currentTime() − R_i < Threshold, w_i ∈ W}
Function FilterCount(R, W):
    Avg ← CalculateAverage({R_i | w_i ∈ W})
    return {w_i | R_i < Avg + θ, w_i ∈ W}
```

首先筛掉unavailable的worker

然后筛掉连接积累过多的worker

最后删掉待处理事件过多的worker

在O(n)时间复杂度下轻量化完成用户态候选worker的筛选

5.2 Hermes实现：多 worker 无锁更新

调度结果同步

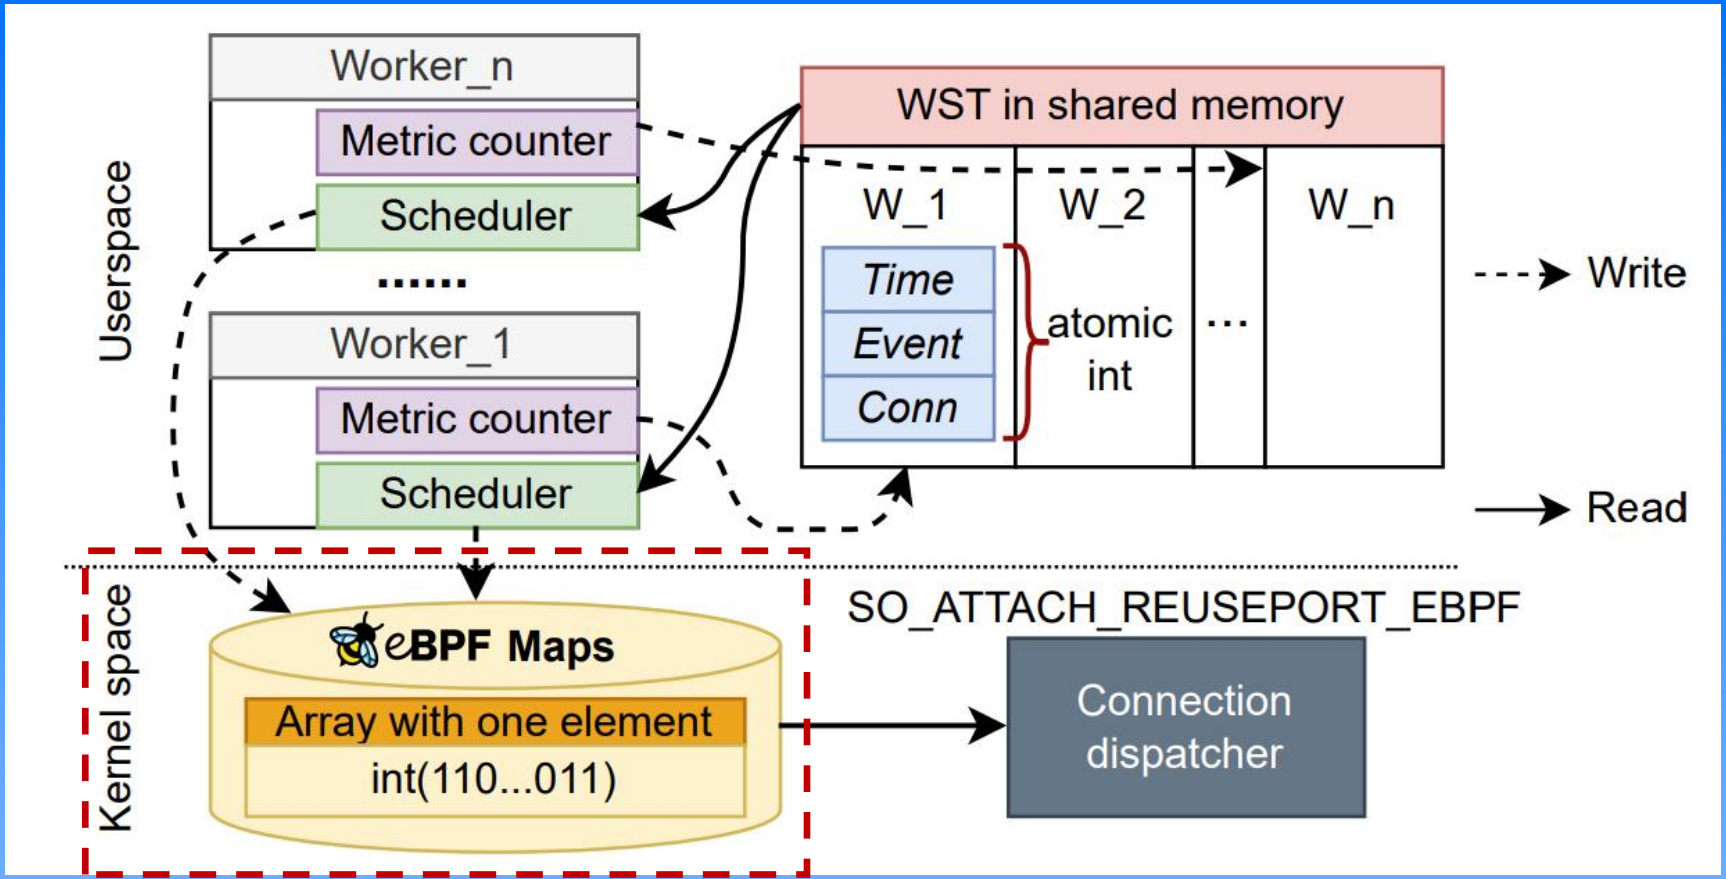

使用atomic<int>存储该0-1比特串，确保原子化读写操作

5.3 Hermes实现：eBPF 内核调度模块

- ✓ 用户态和内核态的两级筛选
- ✓ eBPF 的高效位操作实现

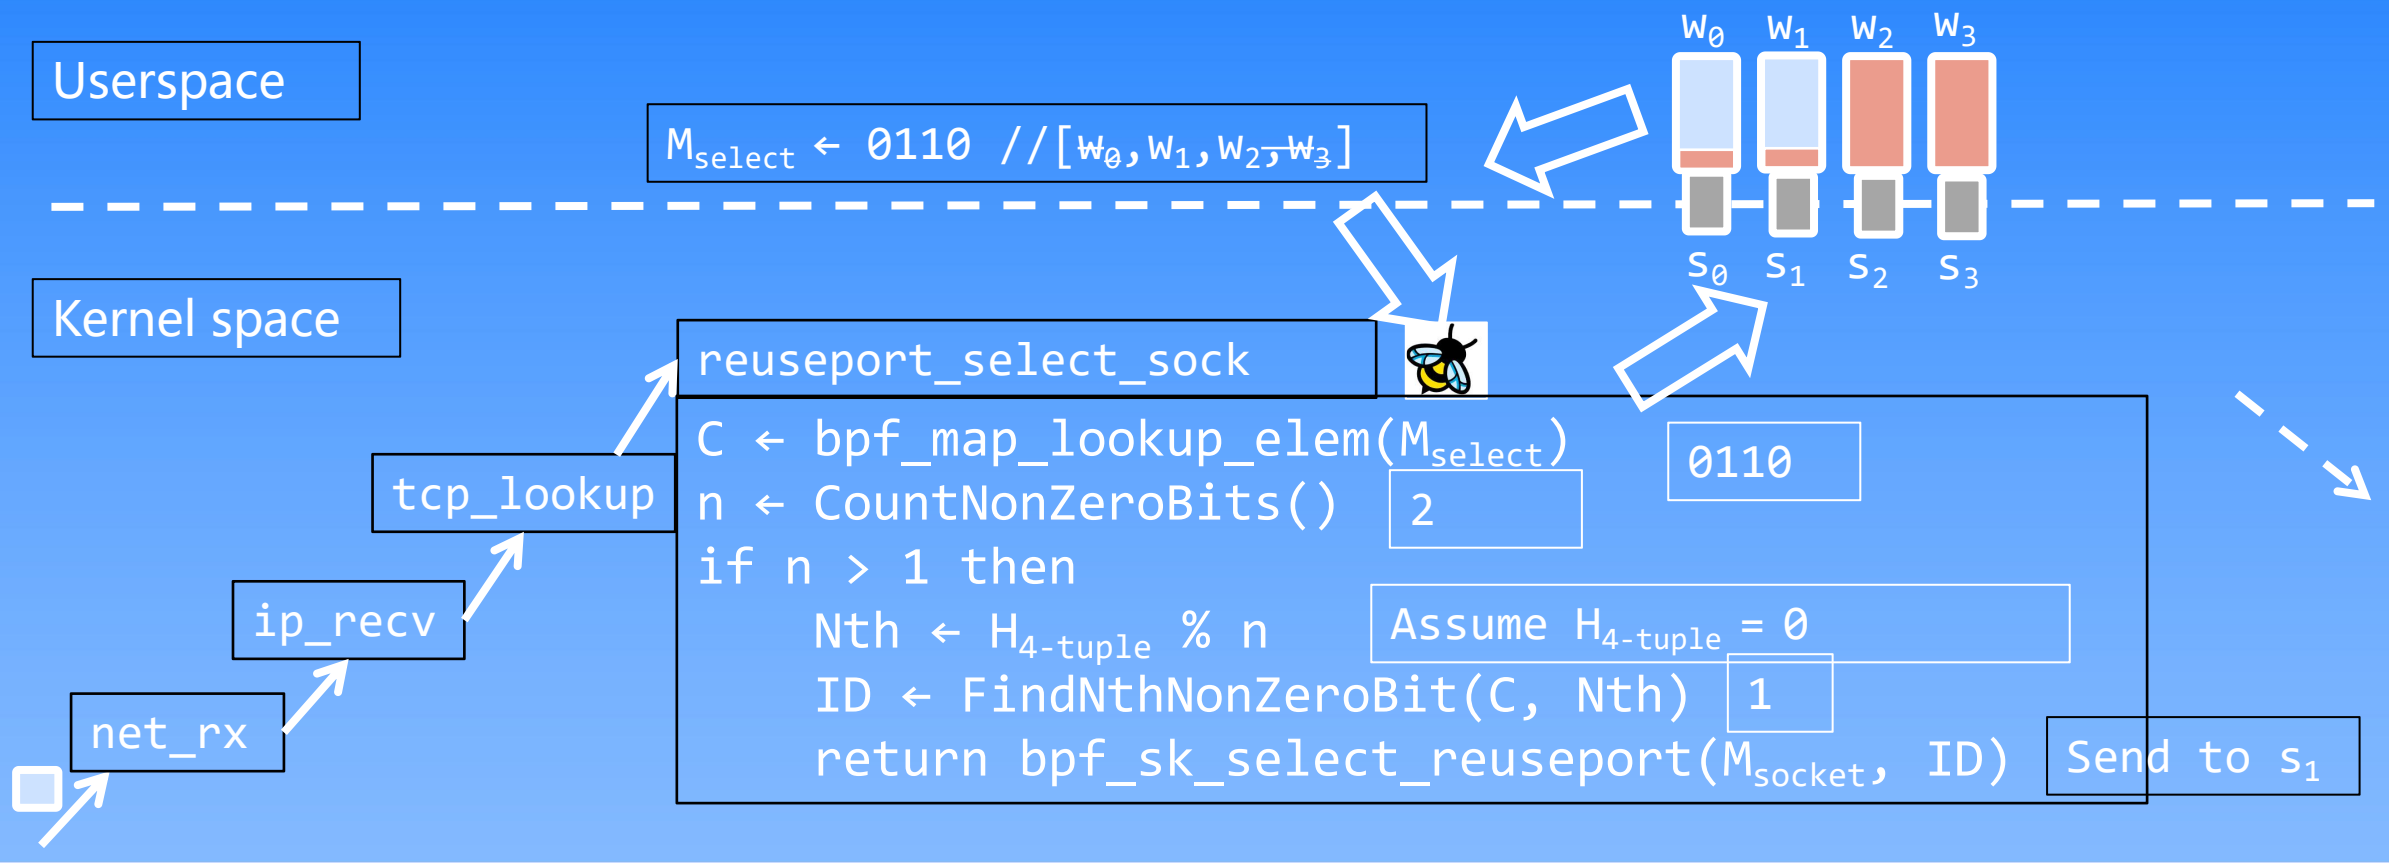

6.1 Hermes 在评估中取得了显著优势

	Epoll exclusive	Reuseport	Hermes
High CPS, Low Avg processing time		✓	✓
High CPS, High Avg processing time			✓
Low CPS, Low Avg processing time		✓	✓
Low CPS, High Avg processing time	✓		✓

主要场景

详细见论文 table 3

6.2 Hermes 部署后延迟与成本均得到优化

谢谢大家

阿里云 ALB 团队 左岳尚
zuoyueshang.zys@alibaba-inc.com