第四届eBPF开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)

陕西 · 西安　　2026年4月18日

https://www.ebpftravel.com

基于eBPF的Linux内核I/O栈性能监测与分析

西安邮电大学 谢瑞莲 索久博

陕西 · 西安 2026年4月18日

I/O性能问题的可观测性困境

周期性I/O突发

难以区分业务流量与异常进程。 IOPS瞬间飙高后回落，无法快速判断是正常高峰还是异常干扰

关联断裂

进程和文件的关联常常断裂。 进程可见但文件不可见，或内核线程发起I/O导致原始进程不可追溯

数据碎片化

缺乏全景分析。 指标零散孤立，延迟构成模糊，单次I/O细节缺失，无法分析长尾延迟

瞬发问题难捕

事后排查无从下手。 问题具有瞬时性，传统工具采样周期长，极易错过峰值窗口，故障现场消失后难以复现。

落盘状态不明

数据落盘不透明， 数据是否真的写到了磁盘上。无法判断瓶颈发生在Page Cache、文件系统还是物理磁盘层。

核心需求：构建端到端、低开销、可追溯的I/O观测体系，实现全链路可见性与精准定位。

Linux系统I/O观测工具能力对比

磁盘统计工具 (iostat, sar, vmstat)

- 输出整盘IOPS、吞吐量、平均延迟与利用率，快速判断繁忙状态。
- 无进程/文件关联能力，无法拆解延迟构成

进程级I/O统计工具 (pidstat, iotop)

- 统计进程总I/O流量，展示进程I/O速率与iowait指标。
- 无法关联具体文件/磁盘；无法追踪内核脏页回写等隐性I/O源头

I/O诊断工具 (iolatency, iohang)

- 拆解I/O延迟层级；检测阻塞I/O请求，定位系统卡顿根因。
- 延迟/卡顿问题，无法定位I/O的具体进程与文件

块层深度追踪工具 (blktrace)

- 拆解I/O q2c总延迟，精细分析块层排队、驱动及硬件耗时。
- 无进程/文件关联，难以形成全链路追溯。

总结：目前无单一工具可完美覆盖“谁在写、写到哪、为什么慢”的全维度诉求，需组合使用。

新一代关联式I/O观测工具

iofsstat (龙蜥)

技术基础：基于ftrace+surftraceI/O的诊断工具

核心能力

- 聚焦进程-文件-磁盘三层关联统计，视角全面
- 输出进程/文件IO指标及磁盘IOPS/BPS/延迟等
- 基于kprobe与/proc/fd匹配，无内核模块依赖

iotracing (滴滴) 2026年1月份开源

技术基础：基于eBPF技术的I/O诊断工具

核心能力

- 覆盖应用到磁盘全链路，支持容器云原生环境
- 追踪内核回写线程背后的原始业务进程
- 拆解q2c/d2c延迟，实时全量采集突刺

Linux I/O全链路分层

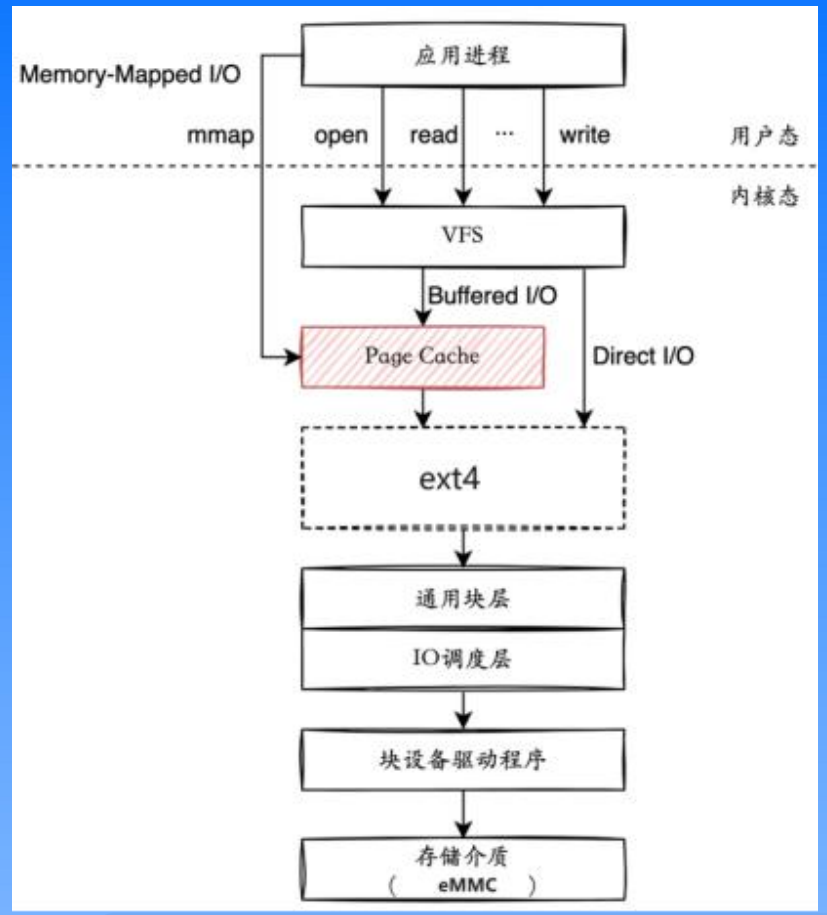

1. 用户态与系统调用层
   应用程序发起I/O请求
2. VFS 虚拟文件系统层
   通用接口层，将ext4、XFS等几十种文件系统，封装起来，向上提供一套统一的抽象接口
3. 页缓存 (Page Cache) 层
   进程读数据时，内核会先检查数据是否在 Page Cache 中，如果在就直接返回；如果不在才会去读磁盘。
   进程写数据时，数据先写入 Page Cache 并标记为“脏”，然后由内核后台线程批量刷入磁盘
4. 通用块层和IO调度层
   把上层的文件请求，转换成标准的块 I/O 请求，把块 I/O 请求合并成一个大的连续请求，再发给磁盘，减少磁盘寻道时间，提升吞吐量
5. 磁盘驱动层
   把内核的软件请求，转换成硬件能听懂的底层指令

I/O 栈监测困难 = 层数深 + 异步延迟写 + 缓存干扰 + 请求变形（拆分/合并/重排） + 地址映射与虚拟化

I/O延迟归因的核心复杂性

延迟叠加效应

问题：总延迟是多层级耗时累加（如缓存阻塞+块层排队+磁盘寻道），难以定位单一瓶颈。

局限：需拆解各环节耗时。

异步I/O溯源断裂

问题：业务写入缓存即退出，实际I/O由内核线程（kworker）异步执行，导致责任断层。

痛点：工具只能看到内核线程，无法追溯原始业务进程，优化方向模糊

瞬时性与采样盲区

问题：大量I/O问题表现为秒级/毫秒级突刺，瞬间飙升后迅速恢复。

局限：周期采样极易错过峰值，需eBPF全量采集留存现场

核心挑战总结：这些复杂性共同构成了诊断难题，凸显了构建全链路、无死角、低延迟的新一代可观测性体系的必要性。

核心挑战一：进程、文件与磁盘的关联打通

eBPF 内核态捕获（文件系统层）

- 进程PID：bpf_get_current_pid_tgid()
- 设备号(dev)：inode->i_sb->s_de
- Inode号：inode->i_ino
- 文件路径、文件名 等等

关联策略：内核态记录 → 用户态解析

01 文件层染色将用户态的进程信息、磁盘信息、文件信息存入 Map1

02 脏页回写
将文件层所填充Map1的key存入新的 Map2

03 数据落盘后的匹配与归因
从Map2 中取出Map1的key，查Map1，最终匹配还原文件、磁盘信息

核心挑战二：页缓存的性能瓶颈

页缓存自身性能瓶颈

页缓存申请变慢 (Direct Reclaim)
场景：内存紧张触发直接回收
后果：进程同步阻塞，导致写延迟剧烈抖动

页缓存提交受阻 (Dirty Threshold)
场景：脏页数量超限，平衡算法介入
后果：进程睡眠，系统iowait升高

eBPF 精准监测方案

统计缓存命中率
探针挂载：add_to_page_cache_lru等
公式：(总访问 - 未命中) / 总访问次数

监测脏页压力
频率：mark_page_dirty 统计新增脏页
阻塞：balance_dirty_pages 捕获阻塞事件

核心挑战三：I/O延迟的层次分解

- 将七层文件系统中写入文件和读取文件的过程，分为四个阶段进行监测
  - 文件写入缓存阶段：监测文件是否成功写入到页缓存中，以及写入的延时
  - 脏页回写阶段：I/O写入请求在脏页回写阶段的延时，以及是否回写成功
  - I/O请求调度阶段：监测I/O请求的调度和CPU处理的延时
  - 设备驱动程序与物理设备写入阶段

核心挑战四：I/O流量分析

- I/O流量数据
  - 文件系统层读取字节总数
  - 文件系统层写入字节总数
  - 块设备层读取字节总数
  - 块设备层写入字节总数

+ 可以直观地看到每个进程对每个文件发起了多少读写流量
+ 便于定位是哪个进程、哪个文件导致了高 IO 负载

实例：写文件延时

```
^[[A^Cyxadmin@SMIOS:~# ./xl_watcher -w
TIME          PID    COMMON          T BYTES   LAT_ns  FILENAME                INODE     RESULT
=================================================================================================
04:16:36:992  4859   test            W 4096    136791  file_32.txt             4003      Success
04:16:36:992  4859   test            W 1024    58333   file_32.txt             4003      Success
04:16:44:992  4859   test            W 4096    143500  file_33.txt             4004      Success
04:16:44:993  4859   test            W 1024    67083   file_33.txt             4004      Success
04:16:45:836  4890   bash            W 39      289334  cmd.log                 34        No space left on device
04:16:52:287  4953   testdbCenter    W 40      711667  msg.log                 27145     Success
04:16:52:287  4953   testdbCenter    W 31      74083   msg.log                 27145     Success
04:16:52:289  4953   testdbCenter    W 40      121625  msg.log                 27145     Success
04:16:52:289  4953   testdbCenter    W 32      125125  msg.log                 27145     Success
04:16:52:993  4859   test            W 4096    141459  file_34.txt             4005      Success
04:16:52:994  4859   test            W 1024    59792   file_34.txt             4005      Success
04:16:53:291  4953   testdbCenter    W 40      110542  msg.log                 27145     Success
04:16:53:291  4953   testdbCenter    W 28      36167   msg.log                 27145     Success
04:16:53:291  4953   testdbCenter    W 40      55708   msg.log                 27145     Success
04:16:53:291  4953   testdbCenter    W 19      42876   msg.log                 27145     Success
04:16:53:293  4953   testdbCenter    W 29      1659000 TaskInfo.log            27146     Success
04:16:53:293  4953   testdbCenter    W 87      77000   TaskInfo.log            27146     Success
```

实例：读文件延时

```
yxadmin@SMIOS:~# ./xl_watcher -r
TIME          PID    COMMON          T BYTES    LAT_ns FILENAME                RESULT
==========================================================================================
04:19:34:195 2465   monitorctlSer    R 4096     47250  monitorSer.json         Success
04:19:34:196 5053   monitorctlSer    R 128      39958  bash                    Success
04:19:34:197 5053   monitorctlSer    R 288      16625  bash                    Success
04:19:34:197 5053   monitorctlSer    R 25       10208  bash                    Success
04:19:34:197 5053   monitorctlSer    R 52       11958  ld-2.21.so              Success
04:19:34:197 5053   monitorctlSer    R 192      10209  ld-2.21.so              Success
04:19:34:199 5053   sh               R 512      35000  libreadline.so.8.1      Success
04:19:34:199 5053   sh               R 512      28000  libhistory.so.8.1       Success
04:19:34:200 5053   sh               R 512      33542  libncurses.so.6.1       Success
04:19:34:201 5053   sh               R 512      35584  libdl-2.21.so           Success
04:19:34:201 5053   sh               R 512      35292  libc-2.21.so            Success
04:19:34:209 5053   sh               R 4096     49875  nsswitch.conf           Success
04:19:34:210 5053   sh               R 4096     13125  nsswitch.conf           Success
04:19:34:210 5053   sh               R 512      36166  libnss_files-2.21.so    Success
04:19:34:211 5053   sh               R 4096     67083  passwd                  Success
04:19:34:213 5054   sh               R 128      44042  coreutils               Success
04:19:34:213 5054   sh               R 288      33250  coreutils               Success
04:19:34:213 5054   sh               R 25       11958  coreutils               Success
```

实例：文件系统缓存

```
^Cyxadmin@SMIOS:~# ./xl_watcher -c
TIME          HITS          MISSES        DIRTIES       HITRATIO(%)       BUFFERS(MB)   CACHED(MB)    MEMAVAIL(MB)
==========================================================================================================================
04:13:49:539  17282         71            69            99.59             0.54          90.50         785.57
04:13:49:654  19112         202           71            98.95             0.54          90.93         785.02
04:13:49:655  19112         203           71            98.95             0.54          91.07         785.02
04:13:49:655  19111         204           71            98.94             0.54          91.07         785.02
04:13:49:655  19110         205           71            98.94             0.54          91.07         785.02
04:13:49:656  19109         206           71            98.93             0.54          91.07         785.02
04:13:49:656  19108         207           71            98.93             0.54          91.07         785.02
04:13:49:656  19107         208           71            98.92             0.54          91.07         785.02
04:13:49:657  19106         209           71            98.92             0.54          91.07         785.02
04:13:49:657  19105         210           71            98.91             0.54          91.07         785.02
04:13:49:657  19104         211           71            98.91             0.54          91.07         785.02
04:13:49:658  19103         212           71            98.90             0.54          91.07         785.02
04:13:49:658  19102         213           71            98.90             0.54          91.07         785.02
04:13:49:658  19101         214           71            98.89             0.54          91.07         785.02
04:13:49:660  19100         215           71            98.89             0.54          91.07         785.02
04:13:49:660  19099         216           71            98.88             0.54          91.07         785.12
04:13:49:660  19098         217           71            98.88             0.54          91.07         785.12
04:13:49:661  19098         218           71            98.87             0.54          91.07         785.12
04:13:49:661  19097         219           71            98.87             0.54          91.07         785.12
04:13:49:661  19096         220           71            98.86             0.54          91.07         785.12
04:13:49:662  19095         221           71            98.86             0.54          91.07         785.12
04:13:49:662  19094         222           71            98.85             0.54          91.07         785.12
04:13:49:662  19093         223           71            98.85             0.54          91.07         785.12
04:13:49:663  19092         224           71            98.84             0.54          91.07         785.12
04:13:49:663  19091         225           71            98.84             0.54          91.07         785.12
04:13:49:663  19090         226           71            98.83             0.54          91.07         785.12
04:13:49:664  19089         227           71            98.82             0.54          91.07         785.12
```

实例：脏页回写延时

```
yxadmin@SMIOS:~# ./xl_watcher -t
TIME         PID    INODE   COMMON      SYNC   WRITEBACK_ns  SCHEDULER_ns  DRIVER_ns   FILENAME          RESULT   BYTES   SECTOR   COUNT  CMD
=================================================================================================================================================
04:21:07:949 4632   4033    ?           async  —             266583        1549334     ?                 Success  8192    526112   16     W
04:21:07:949 4632   4033    ?           sync   397542        —             —           ?                 Success
04:21:18:186 4914   4034    ?           async  —             319959        1738917     ?                 Success  8192    526128   16     W
04:21:18:186 4914   4034    ?           sync   321125        —             —           ?                 Success
04:21:18:186 4914   27150   ?           sync   7584          —             —           ?                 Success
04:21:18:188 4914   27146   ?           async  —             278542        863625      ?                 Success  1024    6611912  2      W
04:21:18:188 4914   27145   ?           sync   2801167       —             —           ?                 Success
04:21:18:189 4914   27146   ?           sync   237417        —             —           ?                 Success
04:21:18:189 4914   27145   ?           async  —             506916        1167250     ?                 Success  2048    6639348  4      W
04:21:23:308 4914   4035    ?           async  —             821916        874126      ?                 Success  8192    526144   16     W
04:21:23:308 4914   4035    ?           sync   2947875       —             —           ?                 Success
04:21:28:424 4632   27149   ?           sync   1529209       —             —           ?                 Success
04:21:28:451 2272   96      dbCenter    async  —             1450459       23510086    T00150020200.db-wal Success 1048576 6455298 2048 W
04:21:28:451 4632   97      ?           sync   209125        —             —           ?                 Success
04:21:28:451 2272   96      dbCenter    sync   2539542       —             —           T00150020200.db-wal Success
04:21:28:465 2272   96      dbCenter    async  —             456458        37406837    T00150020200.db-wal Success 1048576 6457346 2048 W
04:21:28:521 2272   101     dbCenter    sync   93937676      —             —           T00150020200.db   Success
04:21:28:522 4632   27149   ?           async  —             41523129      632917      ?                 Success  2048    6611772  4      W
04:21:28:522 2272   101     dbCenter    async  —             38558337      1786458     T00150020200.db   Success  4096    6625250  8      W
04:21:28:522 2272   101     dbCenter    async  —             38672962      1860833     T00150020200.db   Success  4096    6626010  8      W
04:21:28:522 2272   101     dbCenter    async  —             39839046      1362958     T00150020200.db   Success  4096    6626370  8      W
04:21:28:522 2272   101     dbCenter    async  —             40552170      1189126     T00150020200.db   Success  4096    6626730  8      W
04:21:28:523 2272   101     dbCenter    async  —             41236129      1795500     T00150020200.db   Success  4096    6626906  8      W
```

实例：从磁盘读文件延时

```
yxadmin@SMIOS:~# ./xl_watcher -d
TIME         PID    COMMON       READPAGE_ns  SCHEDULER_ns  DRIVER_ns    FILENAME          RESULT    BYTES   SECTOR   COUNT  CMD
=================================================================================================================================
04:18:05:705 2272   dbCenter     107333       —             —            T00150020200.db   Success
04:18:05:706 2272   dbCenter     —            270958        1194084      T00150020200.db   Success   8192    6634866  16     RA
04:18:05:706 2272   dbCenter     96834        —             —            T00150020200.db   Success
04:18:05:707 2272   dbCenter     73500        —             —            T00150020200.db   Success
04:18:05:707 2272   dbCenter     64167        —             —            T00150020200.db   Success
04:18:05:707 2272   dbCenter     31792        —             —            T00150020200.db   Success
04:18:05:707 2272   dbCenter     39083        —             —            T00150020200.db   Success
04:18:05:707 2272   dbCenter     35291        —             —            T00150020200.db   Success
04:18:05:707 2272   dbCenter     —            82833         1336126      T00150020200.db   Success   16384   6634890  32     RA
04:18:06:69  2272   dbCenter     107625       —             —            T00150020200.db   Success
04:18:06:69  2272   dbCenter     —            945875        783125       T00150020200.db   Success   32768   6634930  64     RA
04:18:06:69  2272   dbCenter     —            1183001       733541       T00150020200.db   Success   20480   6635002  40     RA
04:18:06:69  2272   dbCenter     —            1610001       452958       T00150020200.db   Success   4096    6635050  8      RA
04:18:06:69  2272   dbCenter     —            1856167       669666       T00150020200.db   Success   16384   6635066  32     RA
04:18:06:69  2272   dbCenter     —            1946875       746667       T00150020200.db   Success   8192    6635106  16     RA
04:18:06:69  2272   dbCenter     83417        —             —            T00150020200.db   Success
04:18:06:69  2272   dbCenter     100625       —             —            T00150020200.db   Success
04:18:06:70  2272   dbCenter     —            271542        1225583      T00150020200.db   Success   8192    6635122  16     RA
04:18:06:70  2272   dbCenter     67666        —             —            T00150020200.db   Success
04:18:06:71  2272   dbCenter     143792       —             —            T00150020200.db   Success
04:18:06:71  2272   dbCenter     82833        —             —            T00150020200.db   Success
04:18:06:71  2272   dbCenter     —            78750         1724042      T00150020200.db   Success   16384   6635146  32     RA
04:18:06:275 2272   dbCenter     112291       —             —            T00150020200.db   Success
04:18:06:275 2272   dbCenter     —            926917        1177458      T00150020200.db   Success   36864   6635186  72     RA
04:18:06:275 2272   dbCenter     —            1548459       838542       T00150020200.db   Success   16384   6635266  32     RA
```

实例：读写流量分析（5S）

```
PID     COMMON          F_READ   F_WRITE  D_READ  D_WRITE   FILENAME
=================================================================
2272    dbCenter        0.2MB    9.8MB    0.3MB    10.4MB   T00150020200.db
4953    testdbCenter    0.5MB    1.1MB    0.6MB    1.3MB    msg.log
```

感谢聆听！