第四届eBPF开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)

陕西 · 西安　　2026年4月18日

https://www.ebpftravel.com

DRYWALL

面向 CXL 设备的 eBPF 一致性防火墙

CXL 3.0 | 一致性设备安全 | eBPF 协处理器架构

实现规模: ~11 KLoC • QEMU CXL 模型 • Linux 6.6–6.10

问题：CXL 一致性安全缺口

传统 DMA 防火墙无法保护一致性所有权

传统 DMA 世界

- IOMMU 在地址粒度隔离设备
- DMA 过滤器限制地址范围
- IDE 加密链路传输数据
- 设备作为非一致性 DMA 引擎
- 主机始终拥有规范数据副本

CXL 3.0 一致性世界

- 设备可获取 Exclusive/Modified 所有权
- 规范数据转移至设备 DRAM
- 主机缓存副本被无效化
- 设备重置 = 丢失内核状态
- IOMMU + IDE 均无法阻止此问题

攻击场景

一致性设备异常行为导致的后果

调度器陷阱

设备获取调度队列的 Modified 状态后挂起
→ 主机调度器停滞

故障率 21–91%

Slab 元数据损坏

设备持有空闲链表行写回过期子集
→ 元数据被破坏

故障率 21–91%

加密计数器丢失

LUKS 计数器状态被设备独占，链路抖动
→ 计数器状态损坏

故障率 21–91%

扩展器重放攻击

Type-3 重放旧页面 ECC 校验通过但数据在应用层已过期

故障率 21–91%

Drywall：一致性防火墙概念

过滤所有权，而非仅过滤地址

核心问题：设备可以在 Exclusive/Modified 状态下拥有哪些缓存行？在什么条件下？持续多长时间？采用什么恢复路径？

所有权过滤

基于 ATS 标签的
按页区域策略：
DENY_EXCL
REQUIRE_SHADOW
信用额度限制

影子存储 & 有界撤销

独占前影子复制
撤销截止时限 Δ
带恢复契约

eBPF 协处理器

可提升/可降级
执行引擎
按设备信任等级
模糊测试强化

系统架构

一致性防火墙介入 ATS 和 CXL 一致性控制器之间

eBPF 协处理器：三种运行模式

基于行为的动态信任提升与降级

提升模式
内联防火墙

- 以线速执行策略
- 生成 Merkle 证明
- 维护影子状态
- 内联强制执行不变量
- 需持续良好行为记录

降级

监控模式
（旁路监听）

- 将事件记录到预言流
- 不在关键路径上
- 用于测试/评估阶段
- 向模糊器提供数据
- 新设备的默认模式

违规

隔离模式

- 仅服务重放与清理
- 设备丧失独占权
- 单次违规即触发
- 证明不匹配 → 隔离
- 超时违规 → 隔离

独占前影子复制协议

每次独占授权都附带恢复契约

影子缓存行条目

`data[64]`	缓存行数据副本
`mesi_state`	设备观察到的 MESI 状态
`version`	单调递增计数器
`timestamp`	最后访问时间戳
`device_id`	拥有设备 ID
`checksum[8]`	快速完整性校验

独占协议流程

1. 设备发起 RdOwn（独占请求）
2. 防火墙查询策略（PFN 基数树）
3. 影子副本安装到设备 DRAM
4. 签发撤销票据：Δ=100μs
5. 向设备授予独占权
6. 超时：影子 → 规范数据 + 隔离

撤销时限：Δ_ack = 20μs | Δ_wb = 80μs | 信用额度系统强制执行宽限窗口 | 违规 → 降级 + 信用扣除

模糊测试引导强化

QEMU CXL 模型 + 内核模块协同仿真模糊测试

模糊器

覆盖率引导
变异生成

→

QEMU CXL 设备模型

一致性操作:
RdOwn, WB, Revoke

→

内核模块

防火墙策略
执行与验证

→

eBPF 预言机

不变量检查
与激励生成

第一轮测试发现的缺陷:

- 竞态条件：撤销后的延迟 RdOwn 在无新影子副本情况下重新安装 E 状态
- 队列饥饿：主机撤销操作延迟超过截止时限 Δ
- Merkle 根轮换期间证明纪元不匹配

第 2、3 轮测试: 0 缺陷 • 0 禁止结果 • 19K 唯一状态 • 96% 恢复路径覆盖 • 覆盖率为定向测试的 3.2 倍

Type-3 扩展器的验证内存路径

Merkle 证明防御重放与伪造攻击

Type-3 威胁

- 扩展器可重放旧页面内容
- ECC/CRC 校验通过但数据已过期
- 可在设备层伪造完整性元数据
- 无一致性协议可检测此问题

Drywall 验证路径

- 设备端协处理器计算 Merkle 证明
- 主机在受保护内存中维护根哈希
- 读取返回数据 + 证明供验证
- 按区域动态调整证明严格程度

Merkle 验证流水线

主机根 (受保护) → 验证引擎 → 设备证明 → 接受/拒绝

开销：内存容量的 1–2% • 与标准 ECC + 目录开销相当

性能评估：2–7% 稳态开销

在 Intel Xeon 6787P + QEMU CXL Type-1/3 模型上测评

FIO 存储测试 (dm-crypt/LUKS, 4KB, QD32)

工作负载	基线	Drywall	开销
顺序读	3.20 GB/s	3.14 GB/s	1.9%
顺序写	2.80 GB/s	2.62 GB/s	6.4%
随机读	1.80 GB/s	1.76 GB/s	2.2%
随机写	1.50 GB/s	1.39 GB/s	7.3%
混合 70/30	2.10 GB/s	1.99 GB/s	5.2%

RocksDB 延迟

操作	基线	Drywall	开销
写入 Put	12.3 µs	13.1 µs	6.5%
读取 Get	8.7 µs	8.9 µs	2.3%
迭代 Seek	15.2 µs	15.8 µs	3.9%
压缩	18.7 ms	19.9 ms	6.4%

开销归因分析

- ATS 标签 + 策略查找: 1.7%
- 独占前影子复制: 4.2% (仅写操作，主导写开销)
- 信用 + 撤销 + 队列: 0.6–0.8%
- 总计: 读取 2.8% | 写入 7.3%

安全性与可扩展性

100% 故障遏制 + 线性多设备扩展

一致性压力测试 (每场景 10K 次迭代)

测试场景	基线故障率	Drywall 故障率	恢复时间
脏状态下独占	73.4%	0%	76 µs
延迟写回	48.9%	0%	94 µs
意外移除	91.3%	0%	118 µs
影子抖动	21.3%	0%	83 µs
撤销超时	56.8%	0%	67 µs
并发多行	64.5%	0%	145 µs
热路径竞争	38.9%	0%	58 µs

多设备扩展性

配置	单设备开销	系统吞吐量
1 台设备	5.8%	2.8 GB/s
2 台设备	6.1%	5.3 GB/s
4 台设备	6.3%	10.1 GB/s
8 台设备	6.5%	18.7 GB/s

恢复延迟 (50K 次事件)

- 中位数: 87 µs
- p95: 201 µs
- p99: 271 µs (多行竞争场景)
- 仅隔离路径: 中位数 34 µs

主机内存开销: 每 4KB 页 2 位 (0.006%) | Merkle 元数据: Type-3 容量的 1–2% | 吞吐量线性扩展至 4+ 台设备

核心贡献与总结

1. **一致性防火墙抽象**
   将设备持有的独占权视为一等故障域
2. **ATS 标签策略**
   独占前影子复制 + 按缓存行粒度强制执行
3. **可提升的 eBPF 协处理器**
   三模式架构：内联 → 监控 → 隔离
4. **协同仿真模糊测试**
   QEMU + 内核模块 + eBPF 预言机联合锁步测试
5. **验证型扩展器路径**
   Merkle 证明防御 Type-3 重放/伪造攻击
6. **实际可用的开销**
   2–7% 稳态开销；100% 故障遏制；线性扩展

随着 CXL 技术的普及，一致性防火墙将成为
在部分可信设备环境中保障内核完整性的关键基础设施。