



第四届 e B P F 开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)

基于eBPF的带内带外协同能耗管理技术研究与实践

——面向LLM Token成本最大化

演讲人：焦德伟

<https://www.ebpftravel.com>




第四届 eBPF 开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)

算力“爆炸增长”

•**算力爆炸：**中国智能算力规模的高速增长，本质是全球 AI 算力需求爆发的缩影，而 GPU 是全球 AI 算力的核心硬件载体


EFLOPS



中国智能算力规模及预测（基于FP16计算）

数据中心“耗电增长”

•**能耗同步暴涨：**算力的每一次跃升，都对应着电力需求的同步甚至更快增长，“算力 - 能耗”的强绑定，成为 AI 时代数据中心、能源行业必须面对的核心挑战。





第四届 eBPF 开发者大会

芯片耗电 “触目惊心”


- “LLM大模型单训练集群由2023年的 **千卡规模** (GPT-3、Llama-2) 迅速发展至 **万卡规模** (Llama-3) 甚至 **十万卡规模** (xAI、GPT-5)”
—— [OpenAI](#), [Meta](#), [xAI](#), 2024
- “单芯片 **耗电增长迅速**, 我们无法在同一州放置超过10万片H100进行GPT-6的训练, 否则会导致 **电网崩溃**”
—— Kyle Corbitt with [Microsoft](#), 2024



马斯克旗下xAI的十万卡算力集群，配备的14台柴油发电机供电

算力迭代 “能耗增长”


- 随着大模型训练与推理需求的激增, **GPU技术持续迭代升级**, 以更好地适配当前应用场景。以NVIDIA为例, 近年来推出了包括A100、H100、H200、B200以及面向消费级的RTX 4090、RTX 5090等在内的多款GPU, 显著提升了AI训练及推理的性能。
- 伴随性能的飞跃式提升, **单卡功耗**也随之**大幅攀升**, 能耗增长趋势日益显著。





第四届 eBPF 开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)






第四届 eBPF 开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)


频率、性能、功耗间的关系

- **频率与性能**: 由下图可以看出随着频率下降显卡的性能 (TFlops) 线性的下降, 说明存在明显的**线性关系**。
- **频率与功耗**: 但是频率与功耗之间却不是一个线性关系, 随着频率的降低, 功耗**先快速下降, 再呈现线性关系**。
- **功耗与性能**: 功耗与性能没有直接关系, 但是频率与功耗有直接关系进而**功耗间接影响性能**



电压、频率、功耗间的关系

- **电压与频率**: 电压在一定范围内是不会影响频率, 但是电压过低时会出现**SDC、DUE等故障**。
- **电压与功耗**:
 - 电压的降低最直观的就是功耗的降低, 在相同频率下降低电压会显著降低功耗, 最高能够**降低20%以上**。
 - 在频率很低的情况下 (2000MHz), 芯片内部为了正常工作有最低电压约束, 电压不能够再继续下降。






第四届 eBPF 开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)

大模型推理运行特点

- 负载突发导致硬件功耗**非线性跳升**，计算与内存单元瞬时高频运行引发功耗陡增。
- **频繁波动加剧能效损耗**，电源动态调节与冗余资源待机功耗降低整体效率。
- 高负载触发 **“计算 - 散热” 能耗正反馈**，两者功耗叠加放大总能耗波动。



大模型推理功耗组成

$$Power(t) = Power_{compute}(t) + Power_{memory}(t) + Power_{transfer}(t)$$

- **计算功耗**：矩阵运算和注意力消耗的计算功率，在密集计算时，约为峰值功率的90%。
- **访存功耗**：内存组件访问模型权重和激活所需要的功耗。
- **通信功耗**：特别是模型并行在GPU之间进行大量通信的功耗。

功耗优化机会

- **电压优化**：DVFS技术进行功耗优化
- **频率优化**：根据负载动态调整频率进行功耗优化
- **温度优化**：调整风扇、整机风扇降低温度进行功耗优化
-



第四届 eBPF 开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)

带内观测 (In-Band / OS Level)

技术栈

RAPL, top, cgroups

优势

极高的软件上下文
(PID/Pod级可见性)

劣势

仅为估算值, 存在严重盲区
(无法覆盖风扇、电源损耗及非CPU部件)

带外观测 (Out-of-Band / Hardware Level)

技术栈

BMC, Redfish API, IPMI

优势

100%物理绝对真实
(直读墙上功耗/电源传感器)

劣势

缺乏软件上下文
(对OS和K8s一无所知)


当前困局: 带内有身份无真相, 带外有真相无身份。单向度观测无法支撑精细化管理。



第四届 eBPF 开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)


核心等式：物理真理（带外）
+ 细粒度溯源（带内eBPF）
= 可行动的绿色计算。






第四届 eBPF 开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)





GPU eBPF拦截架构







第四届 eBPF 开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)

大模型推理功耗特征

- **上下文**：512上下文与4K上下文功耗频率相同，整体功耗情况与请求的**上下文长度无关**。
- **并发**：在2、10、50、100并发度测试功耗与频率相同，整体功耗情况与请求的**并发度无关**。
- **请求内部功耗**：Prefill阶段功耗比Decode阶段要高，测试发现普遍**高10%~15%**（不同卡有差异）

模型	并发数量(个)	上下文长度(字节)
Qwen3-32B	2	512
Qwen3-32B	10	512
Qwen3-32B	50	512
Qwen3-32B	100	512
Qwen3-32B	2	4096
Qwen3-32B	10	4096
Qwen3-32B	50	4096
Qwen3-32B	100	4096









第四届 eBPF 开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)

节能效果验证（消费级显卡）

- **频率**：运行节能策略后，设备运行频率从 2950MHz 降至目标值2700MHz。
- **功耗**：平均功耗显著降低，由 290W 降至 237W，**降幅约 18.3%+，峰值功耗降低19%+。**
- **温度**：在负载稳定的情况下，设备平均温度随功耗下降**降低 4°C+；**延长硬件寿命并减少散热能耗。
- **利用率**：节能过程中 GPU 资源**利用率保持稳定**，未出现因降频导致的利用率波动。
- **性能**：从实际吞吐数据来看，模型性能**未受任何负面影响。**

模型	并发数量(个)	上下文长度(字节)	基线	优化后
Qwen3-32B	2	512	124.53	124.11
Qwen3-32B	10	512	504.66	507.57
Qwen3-32B	50	512	1059.97	1038.77
Qwen3-32B	100	512	1668.87	1663.09
Qwen3-32B	2	4096	221.26	224.05
Qwen3-32B	10	4096	736.28	737.42
Qwen3-32B	50	4096	1017.92	1009.38
Qwen3-32B	100	4096	1641.08	1641.85









节能效果验证（数据中心级显卡）

- **功耗优化**：平均功耗降**15.8%以上**，峰值功耗优化效果更显著（35.0%以上），体现节能策略对高负载尖峰的强管控能力。
- **温度改善**：随功耗下降，平均温度**降低 4°C~6°C**，有助于延长硬件寿命并减少散热能耗。
- **性能保障**：性能劣化控制在**~3%以内**，在节能与业务稳定性间实现平衡。

模型	并发数量(个)	上下文长度(字节)	吞吐	优化后
Qwen3-32B	2	512	165.45	159.39
Qwen3-32B	10	512	646.29	627.36
Qwen3-32B	50	512	1662.26	1614.89
Qwen3-32B	100	512	2912.14	2810.28
Qwen3-32B	2	4096	299.58	288.16
Qwen3-32B	10	4096	1014.72	979.79
Qwen3-32B	50	4096	1616.92	1570
Qwen3-32B	100	4096	3052.92	2948.75





第四届 eBPF 开发者大会



The 4th eBPF Developer Conference (eBPFDC 2026)

节能效果验证

- **功耗**: GPU 峰值功耗从 575W 降至约 450W, **降幅超 21%**, 验证极端负载下系统动态能耗管理能力良好。
- **温度**: 芯片工作温度**降低 8°C**, 依据 Arrhenius 方程, 其老化速率可减缓约 5 倍。
- **漏电功耗**: 运行过程中温度升高时, 芯片的漏电功耗会随之增加, 功耗受温度影响。
- **性能情况**: 通过 GPLops 测试, **性能未受影响** (前后均维持在 110TFlops 左右)。

```
83.0% proc'd: 8393 (110554 Gflop/s) - 8175 (109872 Gflop/s) - 8284 (110650 Gflop/s) - 8284 (111132 Gflop/s) - 8284 (112099 Gflop/s) - 8393 (113010 Gflop/s) - 8284 (111334 Gflop/s) - 8284 (111879 Gflop/s) errors: 0 - 0 - 0 - 0 - 0 - 0 - 0 - 0 temps: 81 c - 81 c - 81 c - 76 c - 77 c -
```

```
100.0% proc'd: 9919 (110004 Gflop/s) - 9919 (109894 Gflop/s) - 9919 (110001 Gflop/s) - 9919 (110001 Gflop/s) - 9919 (110001 Gflop/s) - 9919 (110010 Gflop/s) - 9919 (110016 Gflop/s) - 9919 (110001 Gflop/s) errors: 0 - 0 - 0 - 0 - 0 - 0 - 0 - 0 temps: 75 c - 75 c - 75 c - 69 c - 71 c -
```






第四届 eBPF 开发者大会



The 4th eBPF Developer Conference (eBPFDC 2026)

节能效果验证（大规模集群）



本次测试在xxx公司**250台**服务器（总计**1000张**
NVIDIA RTX 409算力卡）上进行全面对比实验，测试周期为12小时压力测试。

- GPU平均峰值运行功率**降低了22.53%**
- 运行时间基本**保持不变**（<3%，属正常机器波动范围）
- 相同计算任务下GPU能耗**平均降低26.32%**
- GPU核心温度平均**下降10.46摄氏度**






第四届 eBPF 开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)


计算错误与幻觉

- **出错概率**：随着电压降低，设备运行过程中出现错误的概率会相应增加。
- **大模型幻觉**：随着电压降低，大模型输出结果的准确性下降，给用户带来的困惑感也会愈发明显。



实际降压测试


- 电压逐步下降至 890mV 时，设备清晰观测到 **CUDA 错误** 与 **SDC 静默数据损坏错误**。
- 进一步降低电压后，芯片因难以维持原有频率而**自动降频**。
- 芯片存在**最低保护电压**，这一机制在电压过低时启动以保障运行稳定。





第四届 e B P F 开发者大会

The 4th eBPF Developer Conference (eBPFDC 2026)



Q&A