



第三届 eBPF开发者大会

www.ebpftravel.com

使用eBPF和Trace技术诊断 Kubernetes下DNS问题

阿里云 曾宇星

中国·西安

关于我



曾宇星

Technical Expert , Alibaba Cloud

Istio & Envoy member, has rich experiences in cloud native fields such as Kubernetes、Networking、Istio、 Envoy、 Nginx Ingress 、 CoreDNS, etc.

目录

- ① 为什么DNS 问题难以排查
- ② DNS问题常用排查方式
- ③ 自动化诊断DNS问题




第三届 eBPF开发者大会

www.ebpftravel.com


① 为什么DNS问题难以排查

中国·西安


Kubernetes 下的DNS 解析链路



Kubernetes 下的DNS 解析链路



Kubernetes 下的DNS 解析链路




复杂度:

- 应用采用不同的语言实现，可能对应不同的DNS Resolver，dns 解析器的行为存在差异
- 本地的/etc/resolv.conf 配置
- IPVS/Iptables 负载均衡和转发问题
- CoreDNS 配置
- CoreDNS 和上游DNS Server 间的网络问题

Kubernetes 下DNS 常见问题

- 应用侧DNS Resolver 的实现缺陷




这只是其中一个例子：

Musl lib 库的处理DNS 逻辑中，针对出现AAAA有NXDOMAIN时，整个域名都会被认为是无法正常解析的

历史原因，不同的解析器不同版本可能存在一些已知问题（历史包袱）

Kubernetes 下DNS 常见问题

- 节点或者Ipsvs、Iptables 问题导致发送端丢包



Error log write: operation not permitted

Kubernetes 下DNS 常见问题


- IPVS 串流问题

<https://github.com/kubernetes/kubernetes/issues/71514>

```
root@k8s-master-1:/# dig www.1.com @172.16.6.139 +timeout=5  
;; reply from unexpected source: 10.242.0.10#53, expected 172.16.6.139#53  
;; reply from unexpected source: 10.242.0.10#53, expected 172.16.6.139#53  
;; reply from unexpected source: 10.242.0.10#53, expected 172.16.6.139#53
```


Kubernetes 下DNS 常见问题

- kube-proxy 异常导致ipvs 下对应的CoreDNS server 地址不同步




Kubernetes 下DNS 常见问题

- CoreDNS 侧节点丢包




Kubernetes 下DNS 常见问题

- CoreDNS 和 上游DnsServer 间的网络问题



Kubernetes 下DNS 常见问题

- VPC 网络原因（路由、安全组配置等）





第三届 eBPF开发者大会


www.ebpftravel.com

② DNS 问题常用的排查方式

中国·西安


CoreDNS 内置的可观测相关插件

插件类别	名称
Logging	log、dump、debug、dnstap
Tracing	trace (CoreDNS 内部)
Metrics	prometheus



CoreDNS 内置的可观测相关插件

插件类别	名称
Logging	log、dump、debug、dnstap
Tracing	trace (CoreDNS 内部)
Metrics	prometheus



查看CoreDNS 日志-Log Plugin

- 仅提供CoreDNS 侧看到的信息

Client IP

Query ID

[INFO] 10.0.3.105:44074 - 15790 "AAAA IN 12fe2448f5b-vqg95.cn-hongkong.nas.aliyuncs.com. udp 75 false 1232" NOERROR qr,rd,ra 161 0.000328346s

Response Code

Response Duration

```
[root@iZj6cfxppumhlian4f1koaZ ~]# k get cm coredns -n kube-system -o yaml
apiVersion: v1
data:
  Corefile: |
    .:53 {
      errors
      health {
        lameduck 15s
      }
      ready
      kubeapi
      k8s_event {
        level info error warning
      }

      kubernetes cluster.local in-addr.arpa ip6.arpa {

        pods verified
        ttl 30
        fallthrough in-addr.arpa ip6.arpa
      }
      prometheus :9153
      forward . /etc/resolv.conf {
        prefer_udp
      }
      cache 30 {
        servfail 0s
      }
      log
      loop
      reload
      loadbalance
    }
}
```


相关排查工具: dig/nslookup + tcpdump

问题:

- 容器内缺失相关工具且无法登录, 需要节点权限, 登录节点采用nsenter 方式
- 容器可以exec 登录, 但因为dns 问题无法安装相关排查软件
- dig/nslookup 不能完全模拟客户端dns resolver 解析器的行为
- ...

排查流程繁琐, 耗时过长, 需要有丰富的排查经验


相关排查工具-dnstap



- dnstap 仅在DNS Server 侧采集了相关信息，缺失了业务容器客户端侧的 DNS查询相关信息的抓取。若请求在客户端发送给 CoreDNS 或者其他DNS Server 中途被丢失，无法确认问题。

相关排查工具-Hubble

- 提供 Kubernetes 集群下网络相关监控
- 基于Cilium 和 eBPF (要求安装Cilium CNI 插件并配置DNS traffic visibility)



相关排查工具-Hubble

```
$ hubble observe --protocol dns -f
```

```
Aug 26 13:03:59.569: demo/mypod:49105 (ID:39877) -> kube-system/coredns-6948557899-m7d49:53 (ID:22818) dns-request proxy FORWARDED (DNS Query example.com. A)
Aug 26 13:03:59.570: kube-system/coredns-6948557899-m7d49:43347 (ID:22818) -> 192.168.49.1:53 (world) dns-request proxy FORWARDED (DNS Query example.com. A)
Aug 26 13:03:59.572: kube-system/coredns-6948557899-m7d49:43347 (ID:22818) <- 192.168.49.1:53 (world) dns-response proxy FORWARDED (DNS Answer "93.184.215.14" TTL: 3091 (Proxy example.com. A))
Aug 26 13:03:59.572: demo/mypod:49105 (ID:39877) <- kube-system/coredns-6948557899-m7d49:53 (ID:22818) dns-response proxy FORWARDED (DNS Answer "93.184.215.14" TTL: 30 (Proxy example.com. A))
```

Filtering:

```
$ nslookup -query=a unknown.example.com.
```

```
$ hubble observe --since=5m --protocol dns -o json \
```


```
| jq 'select(.flow.l7.dns.rcode==3) | .flow.destination.namespace + "/" + .flow.destination.pod_name' \
```

```
| sort | uniq -c | sort -r
```

```
1 "kube-system/coredns-6948557899-m7d49"
```

```
1 "demo/mypod"
```

相关排查工具-KubeSkoop



相关排查工具-KubeSkoop

<https://github.com/alibaba/kubeskoop>

容器服务 ACK / 集群列表 / 集群: test-hg / 故障诊断

← 10.0.3.110 -> 192.168.0.10:53


诊断结果

Level	Node	诊断结果
-------	------	------

没有发现明显问题，请结合诊断项结果进一步判断，也可以向我们提交工单

如果诊断结果未能解决您的问题，您可以[提交工单](#)或者[反馈](#)给我们，将有服务人员解决您的问题。

访问全图



相关排查工具-KubeSkoop


← 10.0.3.110 -> 192.168.0.10:53

诊断结果

Level	Node	诊断结果
FATAL	demo/dns-request-pod	iptables: table filter chain OUTPUT is not empty

如果诊断结果未能解决您的问题，您可以[提交工单](#)或者[反馈](#)给我们，将有服务人员解决您的问题。

访问全图



```
[root@iZj6cby9wi329tfyq886g0Z ~]# nsenter -t 57113 -n -- iptables -A OUTPUT -p udp -m statistic --mode random --probability 0.5 -j DROP
```



第三届 eBPF开发者大会

www.ebpftravel.com

③ 自动化诊断DNS 问题

中国·西安

ACK 下DNS 自动化诊断工具

目标:

- 不需要复杂的安装流程和使用文档
- 用户和阿里云技术支持同学都能使用，能界面白屏化最好，低使用门槛；最好是可以做到一键诊断
- 能快速定界，而不是只给出模棱两可或者疑似问题点

DNS 诊断


* Pod Name:

* Pod Namespace:


* 诊断的域名 (FQDN 格式) :

发起诊断

ACK 下DNS 自动化诊断工具



ACK 下DNS 自动化诊断工具



虽然整个请求调用链中的TraceID 不连续，但单个DNS 查询的请求和响应依然可以关联。

ACK 下DNS 自动化诊断工具-案例1

现象:

dns 请求www.aliyun.com 偶发解析失败

```
dns-request-pod:/# dig +noall +comments www.aliyun.com
;; Got answer:
;; ->>HEADER<<- opcode: QUERY, status: NOERROR, id: 30381
;; flags: qr aa rd ra; QUERY: 1, ANSWER: 9, AUTHORITY: 0, ADDITIONAL: 1

;; OPT PSEUDOSECTION:
; EDNS: version: 0, flags:; udp: 1232
; COOKIE: 6cd115049db327a3 (echoed)
dns-request-pod:/# dig +noall +comments www.aliyun.com
;; communications error to 192.168.0.10#53: timed out
;; communications error to 192.168.0.10#53: timed out
;; no servers could be reached
```

常规诊断:




KubeSkoop 网络诊断没发现异常

ACK 下DNS 自动化诊断工具-案例1

DNS 诊断结果: 发送了30个请求, coredns 侧仅收到了14个


链路说明



ACK 下DNS 自动化诊断工具-案例1

DNS 诊断结果:

链路详细说明



DnsPing 探测结果

Dns Server	超时	探测次数	失败次数	成功次数
192.168.0.10:53	700ms	10	6	4
10.0.3.100:53	700ms	10	3	7
10.0.3.99:53	700ms	10	7	3

ACK 下DNS 自动化诊断工具-案例1

模拟根因： dns-request-pod 发送侧采用tc 设置了UDP 报文50%的丢包率

命令：

```
[~]# nsenter -t 57113 -n -- tc qdisc add dev eth0 root handle 1: prio
[~]# nsenter -t 57113 -n -- tc qdisc add dev eth0 parent 1:3 netem loss 50%
[~]# nsenter -t 57113 -n -- tc filter add dev eth0 protocol ip parent 1:0 prio 3 u32 match ip protocol 17
0xff flowid 1:3
```


ACK 下DNS 自动化诊断工具-案例2


现象：dns 请求slowrequest.org 解析失败

```
[root@iZj6cby9wi329tfyq886g1Z ~]# dig +timeout=2 +tries=0 slowrequest.org @192.168.0.10
; <<>> DiG 9.11.36-RedHat-9.11.36-16.0.1.a18.4 <<>> +timeout=2 +tries=0 slowrequest.org @192.168.0.10
;; global options: +cmd
;; connection timed out; no servers could be reached
[root@iZj6cby9wi329tfyq886g1Z ~]# dig +timeout=2 +tries=0 slowrequest.org @192.168.0.10
; <<>> DiG 9.11.36-RedHat-9.11.36-16.0.1.a18.4 <<>> +timeout=2 +tries=0 slowrequest.org @192.168.0.10
;; global options: +cmd
;; connection timed out; no servers could be reached
[root@iZj6cby9wi329tfyq886g1Z ~]# dig +timeout=2 +tries=2 slowrequest.org @192.168.0.10
; <<>> DiG 9.11.36-RedHat-9.11.36-16.0.1.a18.4 <<>> +timeout=2 +tries=2 slowrequest.org @192.168.0.10
;; global options: +cmd
;; connection timed out; no servers could be reached
[root@iZj6cby9wi329tfyq886g1Z ~]# dig +timeout=2 +tries=3 slowrequest.org @192.168.0.10
; <<>> DiG 9.11.36-RedHat-9.11.36-16.0.1.a18.4 <<>> +timeout=2 +tries=3 slowrequest.org @192.168.0.10
;; global options: +cmd
;; Got answer:
;; ->>HEADER<<- opcode: QUERY, status: NOERROR, id: 8159
;; flags: qr aa rd; QUERY: 1, ANSWER: 1, AUTHORITY: 0, ADDITIONAL: 1
;; WARNING: recursion requested but not available

;; OPT PSEUDOSECTION:
; EDNS: version: 0, flags:; udp: 4096
; COOKIE: ba22aae8bdc10823 (echoed)
;; QUESTION SECTION:
;slowrequest.org.                IN      A
;; ANSWER SECTION:
slowrequest.org.                0      IN      A      192.0.2.53

;; Query time: 1000 msec
;; SERVER: 192.168.0.10#53(192.168.0.10)
;; WHEN: Tue Apr 15 14:06:38 CST 2025
;; MSG SIZE rcvd: 87
```

ACK 下DNS 自动化诊断工具-案例2




KubeSkoop 网络探测没发现问题、延迟探测没发现问题

ACK 下DNS 自动化诊断工具-案例2

DNS 诊断结果:

链路说明



DnsPing 探测设置的超时时间为700ms, 图上可以看到客户端应用侧没有接收到CoreDNS 的返回

DNS 诊断结果:

CoreDNS -> dns-request-pod (5000ms)

ACK 下DNS 自动化诊断工具-案例2

模拟根因： DnsPing 探测客户端设置的超时时间为700ms, CoreDNS 延迟5s 响应

Corefile: |

```
.:53 {  
  ...  
}  
  
slowrequest.org {  
  erratic {  
    delay 1 5s  
  }  
}
```

DnsPing 探测结果

Dns Server	超时	探测次数	失败次数	成功次数
192.168.0.10:53	700ms	10	10	0
10.0.3.100:53	700ms	10	10	0
10.0.3.99:53	700ms	10	10	0

谢谢!